Dr. Konrad Völkel
Heinrich-Heine-Universität Düsseldorf
Wintersemester 2026/27

Einführung in Deep Learning
Blatt 3
(9 Punkte, abzugeben bis 12:00 am Mittwoch, dem 04.11.2026)

In diesem Blatt üben wir die Grundlagen, die notwendig sind, um das klassische Perzeptron (mit Updateregel) als Spezialfall des verallgemeinerten Perzeptron (mit allgemeiner Updateregel, die sich aus einer Loss-Funktion ergibt) aufzufassen. Da das 'Lernen' ein Gradientenabstieg ist, müssen wir Gradienten, d.h. Ableitungen, tatsächlich berechnen können.

Die Aufgaben 1 bis 4 geben je zwei Punkte, Aufgabe 2b gibt einen Punkt – insgesamt 9 Punkte. Zum Bestehen brauchen Sie die Hälfte davon, also 4,5 Punkte: entweder zwei bis drei Aufgaben mehr oder weniger korrekt lösen, oder aber alle Aufgaben ein bisschen.

Hinweise.
- *Das Beispiel mit der Betragsfunktion ist banal, aber wichtig. Versuchen Sie zu verstehen, dass die veränderte Vorzeichenfunktion "quatschi" mit* $\mathrm{quatschi}(x) = \mathrm{sign}(x)$ *für* $x \neq 0$ *und* $\mathrm{quatschi}(0) := 100$ *ebenfalls eine schwache Ableitung der Betragsfunktion ist.*
- *Lassen Sie sich nicht von Integralen einschüchtern, denn um die geht es "in Wirklichkeit" nicht. Aber Integrale haben eine besondere Eigenschaft, die hier zur Geltung kommt, gerade bei dem Beispiel oben: Der Wert an einem einzelnen Punkt spielt keine Rolle.*
- *Wir brauchen das später beim Gradientenabstieg und bei Backpropagation, damit wir auch Funktionen mit Knick (wie ReLU) ableiten können. Die Kettenregel in der Form für Vektoren steht im Kapitel "Gradientenabstieg":*
  `https://eidl-skript-131e30.pages.cs.uni-duesseldorf.de/gradientenabstieg/`

Verallgemeinertes Perzeptron

Bemerkung. *Es gibt Funktionen* $f\colon \mathbb{R} \to \mathbb{R}$*, die nicht überall differenzierbar sind (d.h. die an manchen Stellen keine Ableitung haben). Ein klassisches Beispiel einer solchen Funktion ist der Absolutbetrag* $f(x) := |x|$*, denn der Funktionsgraph hat einen 'Knick' bei* $x = 0$*, sodass man an der Stelle keine 'beste' lineare Näherung an den Funktionsgraph anlegen kann (keine Tangente). In der* ϵ-δ*-Charakterisierung der Ableitung ist die Ableitung an der Stelle* $x = 0$ *als Grenzwert* $\lim_{h\to 0} \frac{f(h)}{h}$ *definiert, der nicht existiert. Es existieren die einseitigen Grenzwerte* $\lim_{0>h\to 0} \frac{f(h)}{h} = -1$ *und* $\lim_{0<h\to 0} \frac{f(h)}{h} = +1$*, die aber verschieden sind.*

Die Ableitung f' *einer Funktion* $f\colon \mathbb{R} \to \mathbb{R}$ *hat die Eigenschaft, dass* $\int_a^b f'(x)dx = f(b) - f(a)$ *ist. So ein Zusammenhang lässt sich auch für die Betragsfunktion herstellen.*

Definition. *Wir nennen eine Funktion* $g\colon \mathbb{R} \to \mathbb{R}$ *eine* schwache Ableitung *von* f*, wenn für alle* $a < b$ *gilt:*

$$\int_a^b g(x)dx = f(b) - f(a).$$

Beispiel: Die Betragsfunktion hat als schwache Ableitung die Vorzeichenfunktion $\mathrm{sign}\colon \mathbb{R} \to \mathbb{R}$ mit $\mathrm{sign}(0) = 0$ und $\mathrm{sign}(x) = \frac{x}{|x|} \in \{\pm 1\}$ sonst.

Aufgabe 1. *Bestimmen Sie eine schwache Ableitung* $g\colon \mathbb{R} \to \mathbb{R}$ *für die* Maximums-Funktion

$$m(x) := \max(0, x) = \begin{cases} 0, & x \leq 0 \\ x, & x \geq 0. \end{cases}$$

Einführung in Deep Learning
Blatt 3
(9 Punkte, abzugeben bis 12:00 am Mittwoch, dem 04.11.2026)

Tipp: Überlegen Sie, dass die schwache Ableitung mit einer normalen Ableitung übereinstimmen kann, an den x, an denen $m(x)$ in einem Intervall um x differenzierbar ist. Sie müssen keine Integrale berechnen.

Aufgabe 2. *Sei $x \in \mathbb{R}^n$ und $s\colon \mathbb{R}^n \to \mathbb{R}$ gegeben als $s(w) := w \cdot x$ (Skalarprodukt). Bestimmen Sie die Ableitungen von s nach den einzelnen w_j, d.h. $\frac{d}{dw_j} s(w)$ für $j = 1, \dots, n$.*

Tipp: Überlegen Sie sich erst die Fälle $n = 1$ und $n = 2$.

Aufgabe 2b. *Sei $x = (2, -1)$ fest und $L(w) := (1 - w \cdot x)^2$. Bestimmen Sie $\frac{\partial L}{\partial w_1}$ und $\frac{\partial L}{\partial w_2}$ mit der Kettenregel und werten Sie beide an $w = (1, 0)$ aus. Prüfen Sie Ihr Ergebnis numerisch: Berechnen Sie $\big(L(w + he_j) - L(w)\big)/h$ für $h = 0{,}01$ und $j = 1, 2$ (mit NumPy, oder von Hand). Wie groß ist die Abweichung, und warum ist sie nicht 0?*

Aufgabe 3. *Seien $y \in \{0, 1\}$ und $x \in \mathbb{R}^n$ fest. Bestimmen Sie mit Hilfe der Kettenregel $\frac{d}{dx} f(g(x)) = f'(g(x))g'(x)$ eine schwache Ableitung nach w_j für die Funktion $L_{x,y}\colon \mathbb{R}^n \to \mathbb{R}$ mit der Definition $w \mapsto L_{x,y}(w) := \max(0, (1 - 2y)(w \cdot x))$.*

Aufgabe 4. *Gegeben sei ein Datenpunkt $x \in \mathbb{R}^2$ mit Label $y = 1$ und ein Perzeptron mit Gewichtsvektor $w^{(0)} \in \mathbb{R}^2$ sodass $w^{(0)} \cdot x < 0$ ist, also x fälschlicherweise das Label $[w^{(0)} \cdot x > 0] = 0$ zugewiesen bekommt. Die Update-Regel definiert einen neuen Gewichtsvektor $w^{(k+1)} := w^{(k)} + r\left(y - [w^{(k)} \cdot x > 0]\right) x$ (in Abhängigkeit von einer Lernrate r, z.B. $r = 0.001$). Überlegen Sie, warum das gilt: wenn man oft genug ein Update durchführt, dann wird x irgendwann richtig klassifiziert (mit $w^{(k)}$ für hinreichend großes k).*

Tipp: Berechnen Sie $w^{(1)} \cdot x$ mit Hilfe der Bilinearität des Skalarprodukts.

Bemerkung. *Wenn $g, h\colon \mathbb{R} \to \mathbb{R}$ Funktionen mit (schwachen) Ableitungen $g', h'\colon \mathbb{R} \to \mathbb{R}$ sind, und mit einem festen $c \in \mathbb{R}$ eine Funktion $f\colon \mathbb{R} \to \mathbb{R}$ stückweise definiert wird als*

$$f(x) := \begin{cases} g(x), & x < c, \\ h(x), & x \geq c, \end{cases}$$

dann hat auch f eine schwache Ableitung, mit einem frei zu wählendem $\alpha \in \mathbb{R}$ nämlich

$$f'(x) := \begin{cases} g'(x), & x < c, \\ \alpha, & x = c \\ h'(x), & x > c. \end{cases}$$

Dabei haben wir (ziemlich frech) wieder f' geschrieben, obwohl diese Funktion keine Ableitung im herkömmlichen Sinne sein muss (sondern eben nur eine schwache Ableitung).

Mit dieser Bemerkung muss man, um schwache Ableitung für stückweise differenzierbare Funktionen anzugeben, nie wirklich Integrale berechnen. Es bleibt Ihnen überlassen, diese Bemerkung zu beweisen (ohne Punkte).