Dr. Konrad Völkel Heinrich-Heine-Universität Düsseldorf
Wintersemester 2026/27

Einführung in Deep Learning
Blatt 5
(11 Punkte, abzugeben bis 12:00 am Mittwoch, dem 18.11.2026)

Die Aufgaben 1 bis 5 geben je zwei Punkte, Aufgabe 1b gibt einen Punkt – insgesamt 11 Punkte. Zum Bestehen brauchen Sie die Hälfte davon, also 5,5 Punkte.

Am Ende des Blattes stehen zwei **Anwesenheitsaufgaben**: Die rechnen wir gemeinsam in der Übung, sie werden nicht abgegeben und geben keine Punkte.

Hinweise.
- *Lesen Sie das Kapitel "Logistische Regression" nochmal aufmerksam, dort stehen die Rechnungen, die Aufgabe 3 (Softmax gegen Sigmoid) braucht:*
  `https://eidl-skript-131e30.pages.cs.uni-duesseldorf.de/logistische-regression/`
- *Wenn Sie sich bei Aufgabe 1 (Ableitung von σ) schwer tun, vollziehen Sie zunächst die Rechnung $\sigma(-x) = 1 - \sigma(x)$ aus demselben Kapitel nach.*
- *Aufgabe 1b und 4 schließen an das Kapitel "Gradientenabstieg" an, Abschnitt "Und zurück zur logistischen Regression":*
  `https://eidl-skript-131e30.pages.cs.uni-duesseldorf.de/gradientenabstieg/`
- *Aufgabe 5 und die Anwesenheitsaufgaben gehören zum Kapitel "Hintergrundwissen Analysis" – dort stehen die Definitionen von Gradient, Jacobi-Matrix und Richtungsableitung, die Sie brauchen:*
  `https://eidl-skript-131e30.pages.cs.uni-duesseldorf.de/hintergrundwissen-analysis/`

Logistische Sigmoidfunktion und Softmax

Aufgabe 1. *Die logistische Sigmoidfunktion ist gegeben als*

$$\sigma\colon \mathbb{R} \to (0,1) \qquad \sigma(x) := \frac{1}{1+e^{-x}}$$

Beweisen Sie

$$\sigma'(x) = \sigma(x)\sigma(-x).$$

Tipp: Benutzen Sie erst die Quotientenregel zur Berechnung von $\sigma'(x)$, dann multiplizieren Sie den entstehenden Ausdruck mit $1/\sigma(-x)$ und formen Sie so lange um, bis die Definition von $\sigma(x)$ da steht.

Aufgabe 1b. *Sei $y \in \{0,1\}$ fest und $L(z) := -y \ln \sigma(z) - (1-y)\ln(1-\sigma(z))$. Zeigen Sie mit Aufgabe 1, dass $L'(z) = \sigma(z) - y$ ist. Folgern Sie: Der Gradientenabstieg auf der binären Kreuzentropie für das Modell $\sigma(w \cdot x)$ hat die Update-Regel $w_{neu} = w_{alt} + \rho\,(y - \sigma(w_{alt} \cdot x))\,x$. Vergleichen Sie mit der Perzeptronregel aus dem Kapitel "Das Perzeptron trainieren".*

Aufgabe 2. *Die Sigmoidfunktion kann verwendet werden, um beliebige Werte $x \in \mathbb{R}$ in Zahlen zu verwandeln, die wie Wahrscheinlichkeiten aussehen, also $\sigma(x) \in (0,1)$. Wenn man keine binäre Klassifikation sondern eine ternäre Klassifikation durchführt, fragt man nicht nur nach der Wahrscheinlichkeit für Klasse 0 bzw. die Gegenwahrscheinlichkeit für Klasse 1, sondern muss 3 Wahrscheinlichkeiten diskutieren, die zu 1 aufsummieren.*

Einführung in Deep Learning
Blatt 5
(11 Punkte, abzugeben bis 12:00 am Mittwoch, dem 18.11.2026)

Die (ternäre) Softmax-Funktion $sm\colon \mathbb{R}^3 \to \mathbb{R}^3$ ist definiert komponentenweise durch

$$sm_j(v) = \frac{e^{v_j}}{\sum_{k=1}^{3} e^{v_k}}.$$

Berechnen Sie für die folgenden drei Vektoren $u, v, w \in \mathbb{R}^3$ die jeweiligen Softmax-Vektoren $sm(u), sm(v), sm(w)$.

$$u = \begin{pmatrix} \log(1) \\ \log(2) \\ \log(3) \end{pmatrix},\ v = \begin{pmatrix} -\log(3) \\ \log(2/3) \\ 0 \end{pmatrix},\ w = \begin{pmatrix} 1.099 \\ 0.693 \\ -3^{1000} \end{pmatrix}$$

Tipp: als Probe können Sie die Summe aller Komponenten von $sm(v)$ bilden, es sollte 1 heraus kommen.

Aufgabe 3. *Die binäre Softmax-Funktion $sm\colon \mathbb{R}^2 \to \mathbb{R}^2$ ist definiert komponentenweise durch*

$$sm_j(v) = \frac{e^{v_j}}{e^{v_1} + e^{v_2}}.$$

Für einen gegebenen Eingabewert $x \in \mathbb{R}$, finden Sie $v \in \mathbb{R}^2$ sodass $sm_1(v) = \sigma(x)$ und $sm_2(v) = 1 - \sigma(x)$.

Tipp: probieren Sie möglichst einfache Werte für v_1 bzw. v_2 aus.

Bonusaufgabe: können Sie zwei verschiedene solche v für ein festes x finden?

Einführung in Deep Learning
Blatt 5
(11 Punkte, abzugeben bis 12:00 am Mittwoch, dem 18.11.2026)

Kreuzentropie als Loss-Funktion

Aufgabe 4. *Auf der Suche nach einem Gütemaß (einer Loss-Funktion) für ein binäres Klassifikationsproblem ist ein natürlicher Kandidat die Kullback-Leibler-Divergenz (relative Entropie) zwischen der Verteilung q der tatsächlich korrekten Labels y_{true} und der Verteilung p der geschätzten Labels y_{pred}:*

$$D(q\|p) = q(0)\log\left(\frac{q(0)}{p(0)}\right) + q(1)\log\left(\frac{q(1)}{p(1)}\right).$$

Diese wird 0 genau dann, wenn die Verteilungen übereinstimmen. In der Praxis verwendet man meist die binäre Kreuzentropie (binary cross entropy BCE):

$$BCE(q,p) := -q(0)\log\left(p(0)\right) - q(1)\log\left(p(1)\right).$$

Beweisen Sie:

$$D(q\|p) = BCE(q,p) - H(q).$$

Dabei ist $H(q) = -q(0)\log(q(0)) - q(1)\log(q(1))$ die Entropie von q und dieser Zusammenhang erlaubt uns, BCE ebenso zu verwenden wie $D(q\|p)$, wenn wir uns nur für die Ableitung nach p interessieren (denn $\frac{d}{dp}H(q) = 0$).

Gradient und Richtungsableitung

Aufgabe 5. *Gegeben ist die Funktion $f\colon \mathbb{R}^2 \to \mathbb{R}$ mit $(x,y) \mapsto \sin(x)\sin(y)$, die "Eierkartonfläche".*

(a) Berechnen Sie für f den Gradienten $\nabla_w f$ und die Jacobimatrix $J_w f$ an der Stelle $w = (x,y)$.

(b) Berechnen Sie an der Stelle $w = (\pi/4, \pi/4)$ den Funktionswert $f(w)$, den Gradienten $\nabla_w f$ und die Richtungsableitung in Richtung $u = (2,1)$. Übrigens ist $\|u\| = \sqrt{5}$, das könnte hilfreich sein.

Tipp: Verwenden Sie den Gradienten zur einfacheren Bestimmung der Richtungsableitung.

Einführung in Deep Learning
Blatt 5
(11 Punkte, abzugeben bis 12:00 am Mittwoch, dem 18.11.2026)

Anwesenheitsaufgaben, ohne Abgabe

Diese beiden Aufgaben rechnen wir gemeinsam in der Übung. Sie werden nicht abgegeben und geben keine Punkte.

Anwesenheitsaufgabe 1. *Berechnen Sie für*

$$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$$

die Ableitung $\tanh'(z)$ *– mit Hilfe der Quotientenregel oder der Produktregel oder der Kettenregel. Sie dürfen auch* $\tanh z = \dfrac{\sinh z}{\cosh z}$ *mit*

$$\sinh z = \tfrac{1}{2}\left(e^z - e^{-z}\right), \qquad \cosh z = \tfrac{1}{2}\left(e^z + e^{-z}\right)$$

verwenden, denn $\sinh z$ *ist leicht abzuleiten.*

Anwesenheitsaufgabe 2. *Gegeben ist eine Funktion* $f\colon \mathbb{R}^2 \to \mathbb{R}$*; wir stellen uns vor, das sei eine Loss-Funktion, die für zwei Gewichte* $w = (x, y)$ *eine Kennzahl ausrechnet. Konkret sei*

$$f(x, y) = x^2 + 2x + y^2 + 1.$$

Berechnen Sie an der Stelle $w = (0, 0)$ *die Richtungsableitung, also die Änderungsrate, in Richtung* $u = (0, 1)$ *– und zwar über die Definition der Richtungsableitung aus dem Kapitel "Hintergrundwissen Analysis".*